



# ELJAER EDFRANCE EUSEBIO EVANGELISTA

ESTUDIANTE UNIVERSITARIO

## PERFIL PERSONAL

Soy un estudiante universitario, que adora los retos -súper competitivo- y no se rinde fácilmente. Muy detallista, autodidacta y deportista.

## HABILIDADES PRINCIPALES

Manejo de Python

Manejo de Stata

Dominio de R

Manejo de Matlab

Dominio de Visual Basic for Applications para economistas

Manejo de Excel a nivel avanzado (macros)

Dominio de LATEX

Inglés Avanzado

## DATOS DE CONTACTO

Calle José Gálvez 504,  
Urbanización Victoria  
Alta, Huaral, Lima, Perú  
Número de celular: 934367591  
Correo electrónico: eljaer.eusebio@pucp.edu.pe  
LinkedIn: <https://www.linkedin.com/in/eljaer-edfrance-eusebio-evangelista-4507551b4/>



## EXPERIENCIA LABORAL

### CENTRO DE EMPODERAMIENTO Y LIDERAZGO (CELID)

Voluntario en el Área de Consumer Research | Agosto 2021 - Actualidad

Lima, Perú

- Extraer información, limpiar, analizar y visualizar bases de datos otorgada por la organización CELID.
- Proponer, a partir de la revisión de los datos, una propuesta de seminarios, conferencias, actividades, temáticas para ayudar a los jóvenes a mejorar en el aspecto de liderazgo y empoderamiento.

### WORK AND TRAVEL 2019-2020

Waiter at Broadmoor Hotel | Colorado, Estados Unidos

- Atención a los comensales
- Servir la comida, bebidas y el pan
- Recojo de mesa: platos y utensilios
- Limpieza del restaurante

### WORK AND TRAVEL 2018-2019

Beverage person at Ho-Chunk Gaming | Wisconsin, Estados Unidos

- Tomar las órdenes de bebidas de los jugadores del casino
- Trato cordial con el cliente
- Ir a la barra a traer las órdenes de bebidas

### GRUPO DE ESTUDIOS TRIAX

Profesor de Matemáticas | enero 2018 – noviembre 2018

Lima, Perú

- Preparar a los alumnos en álgebra, aritmética, geometría, trigonometría, estadística para el examen de admisión de la PUCP
- Corrección de simulacros en el área de matemáticas



## FORMACIÓN ACADÉMICA

### Pontificia Universidad Católica del Perú

Estudiante de Economía | marzo 2017 – Actualidad

- Tomé el curso de Visual Basic for Applications para Economistas en Grupo Lambda Perú
- Tomé el curso de Python for everybody en la plataforma Coursera
- Llevé el curso Tópicos de Economía Matemática y Computacional (Manejo de Python para Estadística, econometría y Machine Learning) en la Universidad
- Actualmente llevo el curso de Estadística Aplicada: Causal Inference and Machine Learning (Manejo de Python y R en el curso) en la Universidad

- Tomé el curso de Excel desde nivel básico hasta avanzado (uso de macros) en CEPS UNI
- Llevé el curso de MATLAB como curso obligatorio en la universidad. El curso se llamó Actividades en Economía 1
- Estudié inglés hasta el nivel avanzado en el Centro de Idiomas de la PUCP



## REFERENCIAS LABORALES

- Miluska Parchem  
Recursos Humanos, Ho-Chunk Gaming Wisconsin Dells  
Correo electrónico: Mylluzkha.Parchem@ho-chunk.com
- Sean Zimkas  
Recursos Humanos, The Broadmoor Hotel  
Correo electrónico: SZIMKAS@broadmoor.com
- Camila Cuba Jara  
Manager Consumer Research, CELID  
Correo electrónico: camilacubaj@gmail.com

# CERTIFICADO

OTORGADO A:



**EUSEBIO EVANGELISTA, ELJAER EDFRANCE**

POR PARTICIPAR EN EL CURSO DE

## **EXCEL VBA PARA ECONOMISTAS**

Desarrollado del 20 de marzo de 2021 al 02 de mayo de 2021, en un total de 30 horas lectivas, según el temario siguiente: i) Manejo de archivos, libros, hojas y rangos; ii) Uso de bucles y variables de control; iii) Creación de procedimientos y funciones personalizadas; iv) Conocimiento de colecciones, arreglos y control de errores; v) Creación de formularios; vi) Control de interacciones con Word, PowerPoint, Internet (web scraping); vii) Interacción con EViews, Stata, ARIMA X12; viii) Creación de complementos (Add-ins) y Ribbon; ix) Aplicaciones diversas para temas económicos en VBA.

Lima, 02 de mayo de 2021

**William Richard Sánchez Tapia**  
Gerente General

CÓDIGO: A210720



08/21/2020

**Eljaer Edfrance Eusebio  
Evangelista**

has successfully completed

**Using Python to Access Web Data**

an online non-credit course authorized by University of Michigan and offered through  
Coursera

A handwritten signature in black ink, appearing to read 'Charles', followed by a horizontal line.

Charles Severance  
Clinical Professor, School of Information  
University of Michigan

**COURSE  
CERTIFICATE**



Verify at [coursera.org/verify/GYUgEBUNGVE6](https://coursera.org/verify/GYUgEBUNGVE6)  
Coursera has confirmed the identity of this individual and  
their participation in the course.

Maturculado	Participando									
MATRICULADO en ciclo 2021-2 ▾		5 curso(s) (18.00 créditos)		Encuestas de opinión Nefas Horario						
Ciclo	Nombre del curso	Créditos	CENSO SOCIALES	Voto	Tipo H	Horario	Modalidad (*)	Docente	e-mail	
ECO039	ECONOMÍA INTERNACIONAL I	3.00	CENSO SOCIALES	-1	CLA	6621	PRESENCIAL	VEGA DE LA CRUZ, HUGO RAMÉ	✉	
					EXA	6621	PRESENCIAL			
ECO222	SEMINARIO DE ECONOMÍA PERUANA	4.00	CENSO SOCIALES	-1	CLA	6621	PRESENCIAL	SARRAMITES CÁCERES, ROSANNA MANABANDA	✉	
					EXA	6621	PRESENCIAL			
ECO224	ESTADÍSTICA APLICADA	3.00	CENSO SOCIALES	-1	CLA	6721	PRESENCIAL	GUSPÉ ROMÁN, ALEXANDER WILDER	✉	
					PRA	721A	PRESENCIAL			
					EXA	6721	PRESENCIAL			
ECO029	ORGANIZACIÓN INDUSTRIAL	3.00	CENSO SOCIALES	-1	CLA	6623	PRESENCIAL	TAVERA COLUMBA, JOSÉ ABRAHAM	✉	
					EXA	6623	PRESENCIAL			
ECO038	ECONOMETRÍA I	6.00	CENSO SOCIALES	-1	CLA	6621	PRESENCIAL	DARCIANOÚEZ, LUIS JAVIER	✉	
					PRA	621D	PRESENCIAL			
					PRA	6621	PRESENCIAL			



## SÍLABO 2021-2

### **I. INFORMACIÓN GENERAL**

Nombre del curso	: Estadística Aplicada
Código del curso	: ECO224
Carácter	: Electivo
Créditos	: 3
Número de horas de teoría	: 2
Número de horas de práctica	: 2
Profesor del curso	: Alexander Quispe Rojas
Correo electrónico pucp	: alexander.quispe@pucp.pe
Horario clases	: Jueves, de 20 a 22 horas
Jefe de prácticas	: Alexander Quispe Rojas
Horario prácticas	: Viernes, de 8 a 10 horas Viernes, de 10 a 12 horas

### **II. SUMILLA**

Este curso electivo ofrece un puente entre la inferencia causal en el análisis económico y los métodos de aprendizaje automático de máquinas, o Machine Learning (ML). Expone modelos econométricos estructurales clásicos y su versión moderna de Artificial Intelligence (AI), conocida como Directed Acyclic Graphs (DAGs). Proporciona herramientas de inferencia estadística basadas en ML y AI (lasso, random forest y deep neural networks), para inferir parámetros causales y cuantificar la incertidumbre. El curso se dictará desde una perspectiva práctica y aplicada, utilizando lenguajes de programación como R y Python. Paralelamente aprenderemos el sistema de control de versiones en Git y GitHub. Es necesario haber llevado el curso de Econometría 2.

### **III. PRESENTACIÓN**

Este curso está dirigido a estudiantes o egresados de la carrera en economía con conocimientos intermedios de econometría. El curso proporciona un tratamiento aplicado de la inferencia causal moderna con datos de alta dimensión, centrándose en los problemas económicos empíricos encontrados en la investigación académica y la industria tecnológica. Formula problemas en los lenguajes del modelado de ecuaciones estructurales y potential outcomes. Presenta enfoques de vanguardia para la inferencia de parámetros causales y estructurales, incluido el Debiased Machine Learning y Reinforcement Learning.

### **IV. RESULTADOS DE APRENDIZAJE**

Este curso proporcionará herramientas conceptuales, herramientas de implementación, pero también aplicaciones a los problemas económicos empíricos encontrados en la investigación académica y la industria tecnológica. Los alumnos entenderán en qué situaciones aplicar métodos de predicción y en cuáles identificar



relaciones de causalidad partiendo de análisis de grafos. Además, serán entrenados en lenguajes de programación libres: Python y R, muy demandados tanto en la academia como en la industria.

## **V. CONTENIDO DEL CURSO**

### **1. Regresión lineal en dimensiones moderadamente altas. (OLS high $p$ , but $p \ll n$ )**

El método de mínimos cuadrados fue introducido en 1800 por L. Legendre y C.F. Gauss, quien lo usó para adaptarse a modelos estructurales. Es, con mucho, el método estadístico más utilizado en la práctica. Aquí revisamos las propiedades de los mínimos cuadrados en problemas de dimensiones moderadamente altas y su uso para inferencias predictivas y para establecer asociaciones.

### **2. Experimentos aleatorios**

En este bloque comenzamos la discusión de la inferencia causal centrándonos en los ensayos de control aleatorios (ECA). En el ensayo de control aleatorio, las unidades se dividen aleatoriamente en aquellas que reciben un tratamiento y aquellas que no reciben tratamiento (un placebo). Luego calculamos la diferencia en los resultados promedio en los grupos tratados y no tratados, el efecto promedio del tratamiento (ATE). Al considerar las covariables previas al tratamiento, podemos mejorar la precisión de la estimación del ATE o explorar la heterogeneidad entre los subgrupos o ambos. Describimos los métodos para hacerlo y los aplicamos a varios ECA.

### **3. Predicción con modelos lineales de dimensiones altas ( $p > n$ ).**

Discutimos el uso de regresiones penalizadas para construir predicciones en el escenario de alta dimensión, particularmente cuando  $p > n$ . Primero, señalamos a la configuración de alta dimensión como el resultado de tener un conjunto de regresores de alta dimensión, así como de la construcción adicional de regresores técnicos a partir de regresores en bruto. Luego discutimos sobre la regresión Lasso que penaliza el tamaño del modelo por la suma de valores absolutos de coeficientes. Luego, proporcionamos una descripción general de otros métodos de regresión.

### **4. Inferencia con modelos lineales de alta dimensión ( $p > n$ )**

Discutimos la inferencia sobre los efectos predictivos usando métodos de Lasso doble, donde usamos Lasso (al menos) dos veces para obtener los residuos de los resultados y una covariable objetivo de interés, cuyo efecto predictivo nos gustaría inferir. Los efectos predictivos coinciden con los efectos estructurales causales en la asignación aleatoria del tratamiento condicionado a los controles. El enfoque se basa en la *approximate sparsity* de los mejores predictores lineales del resultado y de la covariable objetivo. El estimador resultante se concentra en una  $1/\sqrt{n}$  vecindad del valor verdadero y es aproximadamente gaussiano, lo que permite la construcción de los intervalos de confianza. Se explica la propiedad sesgo bajo del método de Double Lasso a través de la ortogonalidad de Neyman, y se aísla esta última como propiedad crítica para generalizaciones posteriores.

### **5. Identificación causal por condicionamiento / DAG lineales**

Se discute cómo los efectos causales promedio pueden identificarse mediante regresión. En este método, se calcula la diferencia promedio entre los resultados esperados para las unidades tratadas y no tratadas que son comparables (formalmente, idénticas) en términos de sus características. Si la asignación del tratamiento es tan buena como la asignación aleatoria condicional en  $X$ , entonces este enfoque recupera los efectos promedio



causales o de tratamiento. Se explora este método a través de los lentes de un marco de potential outcomes , y luego a través del marco del modelo de ecuación estructural y los diagramas causales.

## 6. Predicción en regresiones no lineales modernas (*Random Forest* y *Deep Neural Networks*)

Se discute los métodos de regresión basados en modelos de árbol y *deep neural networks*. Los métodos basados en árboles incluyen árboles de regresión, *Random Forest* y *Boosted Trees*. Los árboles de regresión son excelentes para la exploración y el análisis explicable, los modelos de *Random Forest* y *Boosted Trees* son excelentes herramientas de predicción para datos estructurados y conjuntos de datos de tamaño intermedio (digamos, hasta varios millones de observaciones). Las redes neuronales son métodos de regresión no lineal extremadamente flexibles y son particularmente exitosos para conjuntos de datos de mayor tamaño.

## 7. DAG y SEM no lineales para identificaciones causales estructurales

Se explora una formulación no paramétrica, completamente no lineal, de diagramas causales y modelos de ecuaciones estructurales asociadas. Se discute los criterios gráficos de identificación de los efectos causales promedio mediante el ajuste de regresión.

## 8. Debiased Machine Learning (DML) Inference para modelos modernos no lineales y parcialmente no lineales

Se discute los métodos de *Debiased Machine Learning* (DML) para realizar inferencias en los efectos predictivos o causales promedio en dos clases importantes de modelos. También presentamos un método DML general para realizar inferencia en un parámetro objetivo de baja dimensión en presencia de nuisance parámetros de alta dimensión que son entrenados utilizando métodos de ML (*Machine Learning*). Dos estudios de casos ilustran el enfoque.

## 9. Modelos causales con variables instrumentales y controles proxy

En este módulo se discute varios modelos con Unobserved Confounders. Comenzamos con el análisis de sensibilidad de la inferencia causal con la presencia de Unobserved Confounders. Luego se discute la identificación de los efectos causales cuando se dispone de variables instrumentales o controles proxy.

## 10. Debiased ML para modelos IV / Proxy, Instrumentos débiles

Se especifican los métodos DML para modelos parcialmente lineales con instrumentos, que surgen por endogeneidad de la variable de política o mediante el uso de controles proxy. También se presentan métodos DML para parámetros LATE en el modelo totalmente no lineal con tratamiento endógeno binario e instrumento binario. Se examina más a fondo cómo se puede modificar el método de inferencia DML para hacer frente a instrumentos débiles e identificación débil en problemas de momento genéricos mediante el uso de Neyman-orthogonal score y el estadístico de Neyman  $C(\alpha)$ .

## 11. Feature Engineering con Deep Learning para inferencia causal y predictiva

Se iniciará con un ejemplo de motivación en el que se considera el problema de predecir precios competitivos de productos dadas sus características (texto en la descripción del producto e imagen del producto). Los precios previstos resultantes se denominan precios hedónicos, y el modelo predictivo de esta forma está motivado por modelos económicos hedónicos de precios. Para predecir los precios, tenemos que convertir el texto y la imagen en características numéricas de dimensiones relativamente bajas, llamadas "embeddings".

ESTADÍSTICA APLICADA (EC0226)								
Formulario de Calificación: $\bullet$ P (20Pnt) + QRp1 + QRp2 + 40Pnt (11/10)								
	Participante	Resuelto	Taller práctico					
Nº	1	1	1	2	3	4	5	6
NUM	-	-	12	18	20	-	-	-



